

学 号 :

21200150105

成绩:

苏州科技大学

毕 业 设 计 （ 论 文 ）

题 目 基于 ResNet 的视网膜疾病分类系统的设计与实现

性 质：毕业设计☒

毕业论文☐

院 系： 电子与信息工程学院

专 业： 人工智能

年 级： 2021

姓 名： 杨文慧

指导教师： 高恩婷

二〇二五年

基于 ResNet 的视网膜疾病分类系统的设计 与实现

摘 要

视网膜疾病的早期识别和诊断对于预防视力丧失至关重要。OCT 图像具备实时性、分辨率高等优势，在医疗领域被广泛应用。然而面对海量的 OCT 数据，传统的图像分类方法依赖医生的人工分析，效率低且容易误诊。为了克服这些局限性，近年来研究者开始尝试将深度学习技术应用于 OCT 图像分类任务中，本文提出了一种基于改进的 ResNet 的视网膜疾病分类系统。该系统基于预训练的 ResNet50 模型引入卷积注意模块来增强特征提取能力，有效地提升了分类算法性能。通过在 Retinal OCT-C8 公开数据集上进行训练和评估，实验结果表明 ResNet50_CBAM 模型的分类效果有明显提升，本文模型的分类准确率、召回值、精确度、F1 值分别达到 97.35%、97.37%、97.36%、97.36%。

关键词：视网膜疾病；深度学习；图像分类；注意力机制；迁移学习

The Design and Implementation of a Retinal Disease Classification System Based on ResNet

Abstract

Early identification and diagnosis of retinal diseases are crucial to prevent vision loss. OCT images have the advantages of real-time and high resolution, and are widely used in the medical field. However, in the face of massive OCT data, traditional image classification methods rely on doctors' manual analysis, are inefficient and easy to misdiagnose. In order to overcome these limitations, researchers have begun to try to apply deep learning technology to OCT image classification tasks in recent years. This paper proposes a retinal disease classification system based on the improved ResNet. The system introduces channel and spatial attention mechanism based on the pre-trained ResNet50 model to enhance feature extraction capabilities, effectively improving the performance of classification algorithms. By training and evaluation on the Retinal OCT-C8 public data set, the experimental results show that the classification effect of the ResNet50_CBAM model has been significantly improved. The classification accuracy, recall value, accuracy and F1 values of this model have reached 97.35%, 97.37%, 97.36%, and 97.36%, respectively.

Key Words : Retinal disease;Deep Learning;Image Classification;Attention Mechanism;Transfer Learning

目 录

第 1 章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 机器学习方法	2
1.2.2 深度学习方法	3
1.3 论文主要研究内容及结构安排	3
第 2 章 相关理论	5
2.1 卷积神经网络	5
2.1.1 卷积层	5
2.1.2 池化层	6
2.1.3 全连接层	6
2.2 经典卷积神经网络模型	7
2.2.1 VGGNet	7
2.2.2 GoogLeNet	7
2.2.3 ResNet	7
2.3 迁移学习	8
2.4 PyQt 介绍	8
2.5 本章小结	9
第 3 章 基于 ResNet 的视网膜疾病分类算法	10
3.1 整体框架	10
3.2 残差网络 ResNet50	11
3.2.1 ResNet 网络结构	11
3.2.2 残差模块	11
3.3 注意力模块	12
3.3.1 CBAM 模块	13
3.3.2 优化模型的构建	15
3.4 训练策略	15
3.5 本章小结	16
第 4 章 视网膜疾病分类系统设计	17
4.1 需求分析	17
4.2 系统总体架构设计	17
4.3 视网膜疾病分类系统实现	18
4.3.1 图像上传模块	19
4.3.2 图像处理模块	19
4.3.3 图像分类与结果展示模块	24
4.4 本章小结	27
第 5 章 实验结果与分析	28

5.1 实验设置	28
5.1.1 数据集	28
5.1.2 数据预处理	29
5.1.3 实验配置	29
5.1.4 评价指标	29
5.2 对比实验	30
5.2.1 优化的 ResNet50 模型性能分析	30
5.2.2 不同分类模型对比	31
5.3 消融实验	33
5.4 本章小结	36
第 6 章 总结与展望	37
6.1 总结	37
6.2 展望	37
致 谢	39
参 考 文 献	40
附录 A 译文	43
Swin Transformer: 使用移位窗口的分层视觉转换器	43
附录 B 外文原文	57
Swin Transformer: Hierarchical Vision Transformer using Shifted Windows	57

第 1 章 绪论

1.1 研究背景及意义

眼睛是心灵的窗户，不仅是情感交流的重要介质，更承担着获取外界信息的主要功能^[1]。视网膜作为视觉系统中关键的感光结构，负责将光信号转化为神经冲动并传导至大脑，其微细结构精密且血管网络密集，对病理变化极为敏感，易受多种眼底疾病侵扰，病变若未及时识别干预可能造成永久性视力丧失^[2]，因此视网膜疾病的早期识别与及时治疗至关重要。

光学相干断层扫描（Optical Coherence Tomography, OCT）作为一种具备非接触、分辨率高等的成像手段^[3]，已广泛用于视网膜疾病的结构评估与疾病诊断，可提供清晰的视网膜横断面图像，准确呈现各层解剖结构，是判定老年性黄斑变性（Age-related macular degeneration, AMD）、糖尿病黄斑水肿（Diabetic macular edema, DME）、脉络膜新生血管（Choroidal Neovascularization, CNV）等疾病的重要影像依据^[4]，如图 1-1 所示 AMD 表现为视网膜色素上皮层隆起、渗出，DME 表现为黄斑囊样低反射区及高反射渗出物。可是，目前大多数 OCT 图像解读依赖眼科医生逐张分析，该方式不仅耗时费力且易受医生经验水平等主观因素影响，随着检查频率和图像数量的急剧增长，传统人工阅片方式已难以满足快速、规模化的临床需求。




图 1-1 OCT 图像

为应对上述挑战，计算机辅助诊断系统（Computer-Aided Diagnosis, CAD）应运而生^[1]，它能自动提取 OCT 图像关键特征、识别结构异常并快速完成分类，辅助医生进行科学的可量化的诊断，成为提升眼科影像判读效率与准确度的重要技术方向。当前以卷积神经网络（Convolutional Neural Network, CNN）为基础的深度学习模型在医学图像分析任务中展现出卓越性能，广泛应用于病灶检测、

图像分割与疾病分类等多个场景^[5]。

本研究引入 CAD 技术进行视网膜 OCT 图像分类，既能缓解医生的阅片压力、提高诊断效率，又能通过智能手段完成大规模自动筛查，及时发现潜在患者并进行早期干预，降低致盲风险，所以该系统具有显著临床实用价值与深远社会意义。

基于上面的内容，本文以深度残差网络（ResNet）为基础，设计并实现了一种面向视网膜 OCT 图像的多类视网膜疾病分类系统。

1.2 国内外研究现状

近年来视网膜疾病分类逐渐成为国内外研究的重点方向，主流的分类策略大致可分为两类：一类依赖于传统机器学习方法，另一类则基于深度学习模型。

1.2.1 机器学习方法

视网膜疾病图像的分类主要依赖于传统的图像处理与机器学习相结合的方式，包括通过图像处理手段提取特征信息、将手工特征输入分类模型进行疾病识别两个关键步骤。

在特征提取方面，常用方法包括局部二值模式（Local Binary Pattern, LBP）^[6]、定向梯度直方图（Oriented Gradient Histogram, HOG）^[7]、主成分分析（Principal Component Analysis, PCA）^[8]、尺度不变特征变换（Scale-Invariant Feature Transform, SIFT）^[9]和空间金字塔匹配（Space Pyramid, SP）^[10]等，这些方法从纹理、边缘及空间结构等不同层面对图像特征进行建模。随后，将提取的特征输入分类器进行判别。常用的分类模型有支持向量机（Support Vector Machine, SVM）^[11]、贝叶斯分类器（Bayesian Classifier）^[6]和随机森林（Random Forest）^[12]，它们在医学图像中具有良好的稳定性和鲁棒性。

Liu 等人^[10]使用多尺度空间金字塔方法有效提取 AMD 图像纹理特征，并实现准确分类^[13]；Alsaih 等^[8]则评估多种特征提取方案，最终采用 SP 对 DME 图像识别，分类精度达 87.5%，但这些方法对特征提取和数据标注依赖较强，难以捕捉深层次语义信息，限制了其在大规模数据集上的适用性，为深度学习发展提供了空间。

1.2.2 深度学习方法

卷积神经网络（CNN）最早应用于手写数字识别，此后逐步被引入各类图像分析任务^[14]。2012 年 AlexNet^[15]成功推动深度学习的广泛应用，随后 VGG^[16]与 ResNet^[17]等经典模型相继问世，深度网络开始在多个领域发挥重要作用。深度学习在大规模数据处理和特征提取方面的优势使其在视网膜疾病分类中取得了显著的进展，其中 ResNet 凭借其独特的残差学习机制成为解决深层神经网络训练难题的重要工具^[21]。

近些年许多研究开始探索如何利用 ResNet 模型自动分析 OCT 图像以提高视网膜疾病诊断的准确性与效率，2017 年 Naseer 等^[18]人将 ResNet 深度残差网络用于糖尿病视网膜病变图像的检测，取得 93.2% 的准确率，展现了其在临床实践中的潜力；2018 年王翀等^[19]提出了一种基于 CNN 的多层次特征融合决策模型，精度达到 94.5%；同一年 Kermany 等^[20]利用预训练的 Inception v3 模型对 OCT 图像进行识别，成功实现 96.6% 的准确率。

尽管 ResNet 通过残差连接缓解了深层网络中的梯度消失问题^[21]，但其作为 CNN 模型仍然存在对远距离像素关系建模不足的局限性，尤其在处理复杂病变时需结合注意力机制等技术进一步优化。

1.3 论文主要研究内容及结构安排

本研究围绕基于深度残差网络 ResNet 的视网膜疾病分类系统展开，目标是辅助临床医生对 OCT 图像进行高效、准确的初筛诊断。本文以 ResNet50 为基础，集成卷积块注意模块（Convolutional Block Attention Module, CBAM）来增强模型对关键病灶区域的特征提取能力，提升八类视网膜疾病图像的分类准确率，同时设计实现一个包含数据加载、数据预处理、图像分类预测等模块的视网膜疾病分类系统。

本论文围绕视网膜 OCT 图像的分类与系统实现展开，全文共分为六章，各章内容安排如下：

第一章为绪论，介绍研究背景与意义、国内外研究现状与发展趋势，明确主要研究内容。

第二章介绍了相关理论与关键技术，包括卷积神经网络，经典的卷积神经网络

络模型和迁移学习等内容。

第三章阐述了基于 ResNet50 的视网膜疾病分类模型的设计思路，包括模型结构的构建与改进。

第四章是分类系统的构建与实现，介绍系统整体架构设计及主要功能模块的具体实现。

第五章呈现实验设计与结果分析，对训练效果进行可视化展示，并通过与其他经典模型的对比实验、混淆矩阵与分类指标评估验证系统的有效性与实用性。

第六章为全文总结与展望，概括研究成果，分析存在的不足并探讨未来的研究方向。

第 2 章 相关理论

在医学图像分析领域深度学习在特征提取与分类方面表现出色，本章主要介绍深度学习核心模型卷积神经网络(Convolutional Neural Network, CNN)和 VGG、GoogLeNet、ResNet 等经典 CNN 模型，并对迁移学习进行探讨，为后续的模型改进和系统设计提供理论基础。

2.1 卷积神经网络

1958 年,Hubel 与 Wiesel^[22]对视觉皮层神经元响应机制的研究,为 Fukushima 提出神经认知机模型奠定了基础^[23],这成为卷积神经网络的理论起源^[24]。CNN 通过端到端学习自动提取图像特征,其空间局部相关性和尺度不变性特性在医疗图像等领域表现优异,如图 2-1 呈现的经典 CNN 架构,通过输入层接收图像数据,再经卷积层提取局部特征,池化层进行特征降维,全连接层整合特征,最终由输出层输出结果。




图 2-1 卷积神经网络结构图

本节将从 CNN 的三个主要组成部分入手，依次介绍卷积层、池化层和全连接层。

2.1.1 卷积层

卷积层是 CNN 中的关键组件,主要用于获取输入图像中的各类特征信息^[10],例如边缘、纹理或形状等。卷积操作通过卷积核(滤波器)在图像上滑动,在每个位置执行逐元素乘加运算生成特征图^[25],其具体过程如图 2-2 所示,它具有局部连接和参数共享^[26]两个核心特性,局部连接减少计算量,参数共享降低模型的复杂度,高效地提取图像的局部特征。




图 2-2 卷积过程图

2.1.2 池化层

池化层通常位于卷积层之后，通过滑动窗口对特征图进行降采样以减小数据的维度并降低计算量^[27]，同时增强模型对图像平移、缩放和旋转的适应性^[28]，以提升训练效率。常见方法有最大池化和平均池化^[29]，前者从池化窗口中选取最大值来突出图像中的显著特征，后者则计算窗口内所有值的平均值，操作原理如图 2-3 所示。



图 2-3 最大池化和平均池化示意图

2.1.3 全连接层

全连接层通常位于卷积神经网络的末端，用于整合提取到的特征并完成分类。卷积和池化后的特征会被展平成一维向量^[30]后送入全连接层，最终通过 Softmax 函数，将得分转化为概率分布以实现分类，其计算表达式如下所示：

$$P(y = i) = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}} \quad (2-1)$$

其中， z_i 表示模型在第 i 个类别上的输出得分， n 是类别总数。通过该函数，所有类别的预测值会被转换为 0 到 1 之间的数值，并且它们的总和等于 1，从而构成一个有效的概率分布。

2.2 经典卷积神经网络模型

随着深度学习的发展，卷积神经网络在图像识别领域取得了显著成果，本节将简要介绍 VGGNet、GoogLeNet 和 ResNet 具有代表性 CNN 模型。

2.2.1 VGGNet

2014 年 VGGNet 由牛津大学计算机视觉团队 Simonyan 等人^[16]提出，使用多个连续的 3×3 卷积核堆叠替代传统的大卷积核结构，在增加网络深度的同时降低参数数量^[31]。VGGNet 的结构简洁统一，所有卷积层均采用相同大小的卷积核，并结合 ReLU 激活函数和最大池化操作以提升模型的非线性表达能力与特征提取能力，但堆叠多个 3×3 的卷积层也导致了模型参数量大、计算资源消耗高^[32]，限制了其在资源受限设备上的部署。

2.2.2 GoogLeNet

2014 年为了致敬 LeNet 提出的卷积神经网络模型，Google 团队提出了 GoogLeNet 深度卷积神经网络模型，其核心思想是引入 Inception 模块^[33]，该模块采用多分支并行结构，同步执行 1×1 、 3×3 、 5×5 卷积运算及 3×3 最大池化操作，通过通道维度的特征拼接实现多尺度特征融合。其中 1×1 卷积层既作为瓶颈层降低计算复杂度，又保留非线性表达能力。这种设计显著提升了模型对图像不同尺度特征的捕获能力，在 ImageNet 分类任务中将 Top-5 准确率提升至 93.3%。然而，其并行结构导致网络参数总量达到 500 万，且 5×5 卷积核的高计算成本使得模型训练需要更大的显存开销与更长的收敛时间。

2.2.3 ResNet

2015 年，何凯明团队^[17]提出残差网络结构（ResNet），其创新点在于引入“残差连接（skip connection）”结构，跳过若干层直接将输入与输出相加，从而有效解决了随着网络层数增加而出现的梯度消失与退化问题^[34]。

ResNet 的核心思想是通过恒等映射将前一层输入直接引入当前层输出中，构建“残差块（Residual Block）”，使深层网络更容易训练^[35]。以 ResNet-50 为例，该网络包含 50 层带参数的结构，由多个残差模块堆叠而成，并通过全局平均池化和全连接层实现最终分类。

相较于 VGG 和 GoogLeNet，ResNet 具有更高的可扩展性和更强的特征表达能力，能够构建数百甚至上千层的深层神经网络，同时保持良好的训练效果开销

也越大。

2.3 迁移学习

卷积神经网络的强大性能往往建立在大规模数据训练的基础上，在医学图像处理领域尤其是视网膜 OCT 图像分类中，标注数据的获取成本高、专业性强，难以构建足够规模的训练集。面对这种小样本问题，从头开始训练深度神经网络效率低下且容易过拟合，导致模型泛化能力下降。

为克服这一问题，迁移学习（Transfer Learning）被广泛引入到医学图像分析任务中，其核心思想是利用源任务中学到的知识迁移应用于目标任务^[36]，先基于源任务（如 ImageNet 图像分类）训练一个深度神经网络模型提取通用的图像特征，再将该模型的参数迁移至目标任务，通过微调或部分重训练适应新任务的数据分布^[37]。通过源域与目标域之间的共享特征空间^[38]，模型可以保留源任务中的特征提取能力并完成目标任务的识别或诊断需求，图 2-4 展示了迁移学习的一般流程。




图 2-4 迁移学习示意图

2.4 PyQt 介绍

PyQt5 是一个用于开发图形用户界面（GUI）的工具，支持 Windows、MacOS 和 Linux 等操作系统上运行，提供很多组件以快速创建应用程序，开发者可以通过 QtDesigner 这样的可视化工具设计界面，并将设计好的 UI 文件转为 Python 代码，大大提高了开发效率^[38]。而信号与槽机制是 PyQt5 中程序不同部分之间进行通信的关键^[39]，确保程序中的各个功能模块可以顺利协同工作。

2.5 本章小结

本章主要从四个方面介绍了相关理论，首先介绍了卷积神经网络的相关知识，包括卷积层、池化层和全连接层，然后介绍了经典的卷积神经网络模，接着介绍了迁移学习策略和开发用户友好界面的工具 PyQt，为后面的模型改进和系统设计提供理论基础。

第3章 基于 ResNet 的视网膜疾病分类算法

在视网膜图像分类任务中，选择适当的深度学习网络架构对提高分类效果至关重要。本文提出了使用迁移学习的 ResNet50_CBAM 分类网络，即在 ResNet50 骨干网络中集成 CBAM，旨在增强模型对关键区域及判别特征的识别能力。

3.1 整体框架

作为一种深度残差网络，ResNet50 具备强大的特征提取能力和良好的训练稳定性，能够有效缓解梯度消失问题，因此被广泛应用于图像分类任务中。

然而视网膜 OCT 图像的病灶区域通常面积较小、边界模糊、灰度对比度低，且不同病变（如 DME 与 CNV）之间形态相似，传统 CNN 往往难以提取关键判别特征。为此，本文在 ResNet50 基础上加入 CBAM 模块，通过在通道和空间两个维度引入注意力机制，引导模型聚焦于最具判别价值的区域，从而提升对细微病灶的识别能力。

考虑到本实验中医学图像样本数量较少，就引入迁移学习策略，加载在大规模自然图像数据集（ImageNet）上预训练的 ResNet50 权重，预训练模型通过海量自然图像学习了通用的视觉特征，具备良好的特征提取能力与泛化能力。相比之下，视网膜 OCT 图像通常具有样本稀缺、结构细节微小、病灶区域不明显等特点，直接训练容易导致过拟合，迁移学习在此背景下可有效缓解数据不足带来的性能瓶颈，提升模型在 OCT 图像分类中的表现。

综上，本文构建的 ResNet50_CBAM 网络结构融合了残差结构的稳定性、注意力机制的特征增强能力以及迁移学习的优势，能够更准确地提取 OCT 图像中的关键病理特征，有效提升视网膜疾病的分类性能，网络整体框架如图 3-1 所示。




图 3-1 CBAM-ResNet 网络结构图

3.2 残差网络 ResNet50

本文以 ResNet50 模型为基础卷积神经网络，该模型在传统的卷积神经网络中将残差结构加入到模型，有效解决了随着网络层数增加出现的梯度消失问题。

3.2.1 ResNet 网络结构

ResNet50 作为经典的深度卷积神经网络架构，其结构主要由六个核心组件构成：输入预处理模块、四个层级递增的残差计算模块以及最终的分类输出模块。在网络深度设计上，四个残差模块分别包含 3、4、6、3 个基础残差单元，共计 16 个残差模块。由于每个残差模块包含 3 个卷积层，网络中共有 48 个卷积层。结合初始的 7×7 卷积层和末端的全连接层，整个网络恰好形成 50 层可训练参数的结构，这正是 ResNet50 名称的由来，其具体网络结构如表 3-1 所示。

表 3-1 ResNet50 网络结构

层名	ResNet 网络结构	输出维度
Conv1	$7 \times 7, 64, \text{stride } 2$	112×112
Conv2_x	$3 \times 3 \text{ max pool stride } 2$	56×56
Conv3_x	$\begin{bmatrix} 1 \times 1, & 64 \\ 3 \times 3, & 64 \\ 1 \times 1, & 256 \end{bmatrix} \times 3$ $\begin{bmatrix} 1 \times 1, & 128 \\ 3 \times 3, & 128 \\ 1 \times 1, & 512 \end{bmatrix} \times 4$	28×28
Conv4_x	$\begin{bmatrix} 1 \times 1, & 256 \\ 3 \times 3, & 256 \\ 1 \times 1, & 1024 \end{bmatrix} \times 6$	14×14
Conv5_x	$\begin{bmatrix} 1 \times 1, & 512 \\ 3 \times 3, & 512 \\ 1 \times 1, & 2048 \end{bmatrix} \times 3$	7×7
	Average pool, 1000-d fc, softmax	1×1

3.2.2 残差模块

2015 年，何恺明等人^[17]提出的 ResNet 架构通过残差学习机制解决了深层网络训练中的梯度消失问题^[40]，如图 3-2 所示，其核心残差模块采用双路径设计：

一条路径进行特征变换 $F(x)$ ，另一条路径直接保留输入 (x) ，最后通过加法操作将两者合起来，数学上，这种结构可表述为：

$$H(x) = F(x) + x \quad (3-1)$$

这种结构确保当 $F(x) \rightarrow 0$ 时网络退化为恒等映射，从根本上避免了深层网络的性能退化问题。




图 3-2 标准残差块

在 ResNet50 的具体实现中上述残差模块采用瓶颈（Bottleneck）结构优化，先使用 1×1 卷积进行通道降维，再通过 3×3 卷积提取空间特征，最后再利用 1×1 卷积恢复通道维度，这种三段式处理在保证特征表达能力的同时显著降低了计算复杂度，ResNet50 的完整残差单元结构如图 3-3 所示。




图 3-3 ResNet50 的完整残差单元结构

3.3 注意力模块

ResNet50 具备较强的特征提取能力，但其对目标区域关注度不足的问题在医学图像中表现尤为明显，所以本文在其基础上引入了 CBAM 模块以增强模型对关键区域的感知能力。

3.3.1 CBAM 模块

CBAM 是 Sanghyun Woo 等人^[41]提出的一种混合注意力机制，通过对卷积块的通道和空间信息进行注意力加权来提高网络的表示能力和泛化能力，通道注意力用于捕捉不同通道之间的互相依存关系。它分别在通道维度和空间维度上对卷积块计算注意力权重^[42]，从而引导网络集中关注图像中更为关键的特征区域，进而提升模型的判别能力。CBAM 包含两个主要的组件：通道注意力模块与空间注意力模块^[43]，共同作用于输入特征图的优化，图 3-4 是 CBAM 的网络结构图。




图 3-4 CBAM 模块

(1) 通道注意力

通道注意力模块通过分配每个通道的权重，强调其在特征表示中的重要性，同时保持通道维度不变，压缩空间维度^[43]。输入特征图经过全局平均池化与最大池化^[44]，生成两个单通道特征图，帮助捕获通道层次的全局信息，从而突出关键通道。接下来，这两个池化后的特征图被送入共享的多层感知机（Multilayer Perceptron, MLP），经过非线性变换后得到通道注意力图，反映了各通道对最终特征图的贡献^[45]。最后，通过 Sigmoid 激活函数对这些通道权重进行归一化处理，并将生成的注意力图与原特征图逐通道相乘，以增强网络对重要通道特征的响应。流程如图 3-5 所示，计算方法为：

$$F^n = \sigma(\text{MLP}(\text{MaxPool}(F)) + \text{MLP}(\text{AvgPool}(F))) \quad (3-2)$$

式中 σ 为 Sigmoid 激活函数，MLP 为多层感知机，AvgPool 与 MaxPool 与分别为平均池化与最大池化操作^[42]。




图 3-5 通道注意力模块

(2) 空间注意力

空间注意力模块是依据每个像素点的重要性分配权重，为输入特征图的空间位置分配权重，保持空间维度不变并对通道维度进行压缩^[44]。输入特征图经过全局平均池化与最大池化操作分别得到捕捉了图像的全局平均信息与全局最大信息的两个特征图^[46]，这两个特征图沿通道维度拼接，形成一个新的特征图。然后，通过一个 7×7 卷积卷积层处理生成空间注意力图，表示图像中每个像素位置的重要性。最后，生成的空间注意力图经过 sigmoid 激活函数进行归一化^[43]，并与原始特征图按像素位置逐元素相乘，使网络能够聚焦于图像关键区域，增强对重要特征的关注和响应，流程如图 3-6，计算方法为：

$$M_c = \sigma(\text{Conv}_{(7 \times 7)}([\text{MaxPool}(F'); \text{AvgPool}(F')])) \quad (3-2)$$

式中 σ 为 Sigmoid 激活函数， $\text{Conv}_{(7 \times 7)}$ 为 7×7 卷积操作，AvgPool 与 MaxPool 分别为平均池化与最大池化操作。




图 3-6 空间注意力模块

3.3.2 优化模型的构建

本研究在 ResNet50 主干网络最后一层残差块（layer4）与全局平均池化层之间嵌入 CBAM 模块，以增强模型对关键特征区域的关注能力。

本研究使用的视网膜 OCT 图像数据集涵盖多种疾病，很多病变区域在图像里结构细微、对比度低且边缘模糊等特点，像 DME 与 CNV 早期有轻度渗出、局部隆起，如图 1-1 所示二者在图像中常具有相似的高反射区域和结构扰动特征，导致传统卷积网络在仅靠局部细节时难以准确区分，所以实验模型更需要具备对全局特征的理解能力并能精准识别关键区域。

本文将 CBAM 模块置于网络高层输出位置，让它在利用深层全局特征的基础上，通过通道与空间维度的注意力机制引导模型聚焦于与病变密切相关的区域，来提升模型对微小病灶的识别能力。同时考虑到计算效率和过拟合风险，只在网络末端引入 CBAM 来控制模型复杂度与训练资源开销，最终将该改进后的模型记为 ResNet50_CBAM，其具体结构如下图 3-7 所示。




图 3-7 ResNet50_CBAM 网络结构

3.4 训练策略

ResNet50_CBAM 模型通过集成 CBAM 模块，有效增强了网络对全局关键特征的关注意，为了进一步提升模型在小样本 OCT 视网膜图像分类任务中的表现，本文采用迁移学习策略，其流程如图 3-8 所示，具体是模型加载了在大规模自然图像数据集（ImageNet）上预训练的 ResNet50 权重，该预训练模型通过海量图

像学习了边缘、纹理等通用的低层次视觉特征，具备较强的特征提取能力，可以减少训练所需的数据量和时间成本，提升整体训练效率。




图 3-8 基于迁移学习的视网膜疾病分类模型流程图

考虑到视网膜 OCT 图像数据规模有限，为防止训练过程中出现过拟合并增强模型对视网膜 OCT 图像的判别能力，本文采用微调策略，冻结了 ResNet50 模型的初始卷积层、Batch Normalization 层、最大池化层及 layer1 残差模块，保留预训练阶段已学习的通用特征；而 layer2、layer3、layer4 模块以及新增的 CBAM 模块与分类层则参与训练，通过参数更新以适应视网膜 OCT 图像任务的特征分布。这种“前层冻结、后层微调”的策略既保留了模型在自然图像中获得的通用特征提取能力，又使模型聚焦于目标任务中具备判别力的细粒度病理特征，提升在小样本医学图像分类任务中的整体性能。

3.5 本章小结

本章针对视网膜疾病图像分类问题开展研究，针对传统方法在复杂医学图像特征提取中的不足，提出基于迁移学习的 ResNet50_CBAM 分类算法。研究对 ResNet50 模型的残差学习机制进行详细分析，该机制通过跨层连接设计解决深层网络训练中的梯度消失问题，为实现高精度分类提供支撑。针对视网膜疾病数据集特点引入卷积注意模块（CBAM）与迁移学习策略，CBAM 的通道与空间双重注意力机制可增强模型对病灶关键区域的聚焦能力以精准捕捉微小病理特征，迁移学习利用预训练模型在大规模图像数据中学习的通用视觉特征并结合视网膜疾病数据集微调，降低训练成本与过拟合风险。

第4章 视网膜疾病分类系统设计

为了使视网膜疾病分类更加便利，本文设计了一款视网膜疾病分类系统以提高模型的应用价值。

4.1 需求分析

为满足视网膜疾病图像自动分类的需求，系统应支持从图像上传、处理到分类推理和结果展示的完整流程，保证操作优化便捷、分类结果准确。支持多种类型的视网膜图像上传并完成归一化、尺寸调整等预处理操作，用户可通过图形界面对图像进行裁剪、旋转、亮度调节等操作以更好地观察病灶区域；在分类推理模块系统将集成 ResNet、VGG、GoogLeNet 多种主流深度学习模型，支持用户切换模型并快速进行推理，及时返回分类结果；系统还需提供直观的结果展示模块，显示预测类别、置信度以及各类别的概率分布，使用户进行后续记录和分析。

4.2 系统总体架构设计

针对上述需求，本实验提供了直观且便捷的操作界面，用户可以轻松完成从图像导入、模型选择、分类执行以及结果展示的全过程，系统的总体架构如图 4-1 所示，核心架构包括图像上传模块、数据处理模块、分类推理模块和结果展示模块。

（1）图像上传模块：负责接收用户上传的图像数据，支持单张图像和批量图像导入，它还将对上传的图像进行预处理，以确保图像符合深度学习模型的输入要求。

（2）数据处理模块：提供对图像的简单处理功能，用户可以对图像进行裁剪、旋转、对比度调整等操作，从而更灵活地观察图像，使其适应疾病诊断任务的需求。

（3）分类推理模块：提供 ResNet、VGG16 和 GoogLeNet 多种深度学习模型供用户选择，在模型选择和图像预处理完成后，用户点击“分类”按钮，系统将调用选定的模型进行前向推理，输出各个类别的预测概率，该模块是整个系统的核心，负责完成图像分类的实际工作。

（4）结果展示模块：分类结果通过图形化界面展示，用户可以查看图像的

预测类别及其置信度。该模块还提供概率分布视图，允许用户查看所有类别的预测结果，状态栏会简洁地显示分类信息，便于用户快速理解输出。




图 4-1 系统整体架构图

4.3 视网膜疾病分类系统实现

本系统的核心功能主要分为图片上传模块、图像处理模块、图像分类与结果展示模块，系统界面如图 4-2 所示。




图 4-2 视网膜疾病分类系统界面

4.3.1 图像上传模块

图像上传模块是视网膜疾病分类系统的关键组成部分，主要负责提供用户与系统之间的交互接口，允许用户上传本地存储的视网膜图像。上传后的图像会经过预处理，并为后续的疾病分类和诊断做准备，其效果如图 4-3 所示。




图 4-3 上传文件

(1) 图像上传接口

通过 PyQt5.QtWidgets 模块的 QFileDialog 类，用户可以选择单个文件、最近打开的文件，或从文件夹中批量选择多个文件进行上传，如此便可以让用户轻松地上传文件，无论是单个图像还是整个文件夹中的多个图像。

(2) 图像加载和预处理

通过 PIL 库对图像进行预处理操作，例如调整图像大小至 224x224 像素，转换为适合深度学习模型输入的格式，并进行归一化。图像归一化操作通过如下公式进行，

$$I' = \frac{I - \mu}{\sigma} \quad (4-1)$$

其中， I 是原始图像的像素值， μ 为图像的均值， σ 为图像的标准差， I' 为归一化后的图像。

4.3.2 图像处理模块

图像处理模块为用户提供了丰富的图像操作功能，帮助用户更好地观察和分

析视网膜图像判断潜在的眼科疾病类型，包括调整对比度、亮度、旋转、裁剪、滤波等操作，每一项操作都旨在增强用户对图像细节的控制和分析能力，下面详细展示几个核心功能。

（1）对比度和亮度调整

系统提供了对比度和亮度调节功能，用户可以通过滑动滑块动态调整图像的对比度和亮度值，优化图像的视觉效果、增强图像细节的显示，在观察视网膜微小病变（如新生血管、黄斑水肿）时，适当提升对比度可以有效突出边缘特征，调整亮度则有助于提升暗部区域的清晰度，该功能通过以下线性变换公式实现：

$$I' = \alpha \cdot I + \beta \quad (4-2)$$

其中， I 是原始图像的像素值， $\alpha=1+\text{contrast}$ 是对比度因子， $\beta=255 \cdot \text{brightness}$ 是亮度偏移量， I' 为调整后的图像。通过这种方法，用户可以动态调整对比度和亮度，增强图像的细节，该功能的效果如图 4-4 所示。



图 4-4 对比度和亮度调整效果图

（2）旋转功能

旋转功能允许医生对图像进行旋转调整，以便从不同的角度观察视网膜图像，帮助医生更好地定位和分析病变区域。用户可以通过旋转滑块调节旋转角度，图像会实时旋转并更新显示，旋转操作使用二维旋转矩阵进行描述，公式如下：

$$M = \begin{bmatrix} \cos \theta & -\sin \theta & (1 - \cos \theta)x - \sin \theta y \\ \sin \theta & \cos \theta & (1 - \cos \theta)y - \sin \theta x \end{bmatrix} \quad (4-3)$$

其中， θ 是旋转角度， x, y 是图像的中心坐标。通过此旋转矩阵，用户可以调整旋转角度，从不同角度观察视网膜图像，该功能的效果如图 4-5 所示。




图 4-5 旋转效果图

（3）裁剪功能

支持图像裁剪操作，用户可通过鼠标拖动在图像上自由框选感兴趣区域，进行局部查看或分析，裁剪操作可通过公式表示。裁剪界面提供可视化边框，用户可随时调整选区范围，界面友好、操作直观，裁剪操作可通过以下公式表示：

$$I'(x,y) = I(x,y) \text{ for } (x,y) \in ROI \quad (4-4)$$

其中， $I(x,y)$ 是原始图像， ROI 表示感兴趣区域， $I'(x,y)$ 为裁剪后的图像，该功能的效果如图 4-6 所示。




图 4-6 裁剪效果图

（4）图像缩放

为方便用户查看图像细节，系统提供放大与缩小两种缩放方式。用户既可通过菜单项选择缩放级别，也可以使用鼠标滚轮进行连续缩放，缩放通过双线性插值算法实现，该功能的效果如图 4-7 所示。




图 4-7 图像缩放

(5) 滤波

本系统包含滤波（去噪）处理模块，用于降低图像中的噪声干扰、提升图像质量，用户可以通过“工具”菜单中的“模糊/去噪”入口对当前图像进行滤波处理，模块支持包括高斯滤波、均值滤波、中值滤波、方框滤波、自定义卷积滤波与双边滤波的去噪方法，系统提供滑动条界面来调整核大小、颜色空间 σ 值与空间 σ 值等各类参数，方便用户根据具体噪声特征进行灵活配置。

高斯滤波是最常用的去噪方法，其滤波核函数如下所示，其中 σ 为标准差， x, y 为像素相对核中心的偏移坐标：

$$G(x, y) = \frac{1}{2\pi\sigma^2} \cdot e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (4-5)$$

均值滤波则通过对邻域像素取平均来实现图像平滑，公式如下所示，其中 Ω 为滤波核的区域， N 为核内像素的数量， $I(x, y)$ 为原图像：

$$I'(x, y) = \frac{1}{N} \sum_{(i, j) \in \Omega} I(x + i, y + j) \quad (4-5)$$

中值滤波使用局部像素的中位值替代中心像素值，更适用于消除椒盐噪声，且边缘保持能力强，公式如下所示：

$$g(x, y) = \text{med}\{f(x - m, y - n)\}, (m, n \in \omega) \quad (4-7)$$

方框滤波是均值滤波的一种扩展形式，在归一化条件下，其计算如下：

$$K = \frac{1}{\alpha} \begin{bmatrix} 1 & \cdots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 1 \end{bmatrix} \alpha = \begin{cases} \frac{1}{\text{width} \times \text{height}} & \text{normalize=true} \\ 1 & \text{normalize=false} \end{cases} \quad (4-8)$$

当参数 `normalize=false` 时，表示不需要进行归一化处理，直接使用邻域像素值的和；当参数 `normalize=true` 时，表示要进行归一化处理，要用邻域像素值的和除以面积。

自定义卷积滤波（`filter2D`）允许用户通过设定卷积核对图像进行任意线性变换，其通用表达式如下，其中 $H(i,j)$ 为卷积核， $I(x,y)$ 为原图像， $I'(x,y)$ 为滤波后的图像：

$$I'(x,y) = \sum_{i=-k}^k \sum_{j=-k}^k H(i,j) \cdot I(x+i,y+j) \quad (4-9)$$

最后，双边滤波结合了空间距离与像素值差异进行加权平均，能够在平滑噪声的同时有效保留边缘细节，其公式如下所示：

$$g(k,l) = \frac{\sum_{i,j} f(i,j)w(i,j,k,l)}{w(i,j,k,l)} \quad (4-10)$$

操作过程中，用户可在左侧预览不同滤波器，并将任意一种效果应用于右侧图像显示区进行比对与确认。点击“应用”按钮后，系统将所选滤波结果作为新的处理图像并回传主界面，该功能的效果如图 4-8 所示，支持不同滤波参数配置，适应不同噪声环境。




图 4-8 滤波效果图

（6）直方图均衡化

系统支持 CLAHE（对比度受限自适应直方图均衡化）和 CDF 均衡化两种直方图均衡化方法，CLAHE 通过限制局部区域的对比度提升防止图像出现过度增强现象；CDF 均衡化则基于全局灰度级的累积分布函数自定义像素映射曲线，从而更细腻地调整图像灰度分布，CDF 均衡化的像素映射函数可表示为：

$$T(r_k) = (L-1) \cdot \sum_{j=0}^k \frac{n_j}{N} \quad (4-11)$$

其中， $T(r_k)$ 表示灰度值， r_k 对应的映射值， n_j 为灰度级 j 的像素数， N 为图像总像素数， L 为灰度级数量（通常为256）。通过此变换，可将原始图像的直方图拉伸至近似均匀分布，从而显著增强图像的对比度表现。




图 4-9 直方图均衡化（CDF）效果图

4.3.3 图像分类与结果展示模块

本模块由图像分类引擎和可视化交互系统组成，采用三个可供选择的深度学习模型（ResNet50、VGG16、GoogLeNet）实现视网膜疾病分类。

该模块根据分类功能的不同使用场景，分别提供单图像、批量图像以及手动标签三类任务的操作与结果展示方式。

（1）单图像分类

该功能主要面向用户对单个图像进行快速推理的需求。

b. 操作流程：用户可通过菜单栏“分析→对单个图像分类”选择并加载目标图像，系统将自动完成图像的标准化处理，并通过深度学习模型进行分类。

b. 结果展示：分类结果包括疾病类型的中文与英文名称、分类置信度，同时辅以概率分布图表，展示效果如图4-10。




图 4-10 单图像分类结果展示

（2）批量图像分类

在临床或研究环境中用户可能需要处理大量的图像数据，为提高大规模图像处理的效率，本系统支持批量图像分类功能。

a. 操作流程：用户点击“分析 → 对所选文件夹批量分类并另存为”功能，对文件夹中的多张图像执行逐张推理，系统自动整理分类结果并以结构化方式呈现。

b. 结果展示：结果区采用表格视图，内容涵盖图像文件名、模型预测类别以及置信评分等要素，特别地当某幅图像的置信评分小于等于0.8时，系统自动将该记录以红色字体标示，提醒用户该分类结果可能存在较高不确定性，需进一步审查，展示效果如图4-11所示。




图 4-11 批量图像分类结果展示

（3）手动标签

考虑到实际应用中，部分图像可能无法通过模型准确识别，系统提供标签模式以支持手动分类。

- a. 操作流程：启用“分析 → 标签模式”，用户可在界面中为当前图像指定标签。
- b. 结果展示：标签选择过程为实时交互，用户设定的标签会即时反映在界面并记录至系统缓存中以支持后续保存操作，效果如图4-12所示。




图 4-12 手动分类效果图

4.4 本章小结

本章聚焦视网膜疾病图像分类需求，完成视网膜疾病分类系统的全流程功能设计与技术实现。系统以操作便捷性和分类准确性为核心，构建了图像上传、处理、分类推理及结果展示的一体化架构。分类推理模块为核心功能模块，包含 ResNet、VGG、GoogLeNet 深度学习模型，支持用户灵活切换模型配置，实现快速推理并即时返回分类结果。系统设计兼顾功能完备性与用户体验，通过模块化架构和交互性设计，既满足视网膜疾病图像自动分类的技术要求，也提升了系统在医学影像辅助诊断场景中的实用性与易用性，为后续系统优化和临床应用奠定坚实基础。

第 5 章 实验结果与分析

5.1 实验设置

5.1.1 数据集

本实验采用的是 Retinal OCT-C8 公开数据集，共收录了 24,000 幅视网膜 OCT 图像，包括老年性黄斑变性（AMD）、脉络膜新生血管形成（CNV）、中浆性渗出性视网膜病（CSR）、糖尿病性黄斑水肿（DME）、黄斑裂孔（MH）、玻璃膜疣（DRUSEN）、糖尿病视网膜病变（DR）以及健康视网膜（NORMAL）8 个临床相关的病理类别，数据集中各类疾病如图 5-1 所示。数据集已被预先划分为训练集、验证集与测试集，图像数量分别为 18,400 张、2,800 张与 2,800 张，具备良好的应用基础与研究价值，数据集的标签信息统计如图 5-2 所示。




图 5-1 视网膜 OCT 图像




图 5-2 数据集分布图

5.1.2 数据预处理

针对视网膜 OCT 图像特点设计的预处理方案在训练阶段对图像进行随机裁剪至 224×224 像素,既满足 ResNet50 模型的输入要求又保留关键的病灶区域特征,同时以 50% 概率进行水平翻转在保证视网膜解剖结构合理性的前提下有效扩充数据量。验证集和测试集则采用中心裁剪的方式以确保评估的稳定性和可重复性,预处理过程中还要特别注意保留原始灰度信息,避免医学诊断特征的损失。

5.1.3 实验配置

(1) 实验环境

本实验基于 PyTorch 框架的 GPU 版本构建卷积神经网络模型并进行训练实验,运行平台为 Windows 10 家庭中文版操作系统。选用 PyCharm 2022.3.3 作为开发环境,编程语言采用 Python 3.9 版本,相关开发环境配置详见表 5-1。

表 5-1 开发环境

名称	版本
开发编辑工具	PyCharm 2022.3.3
开发语言	Python 3.9
包管理工具	Anaconda3
深度学习框架	PyTorch GPU 1.12.1
CUDA 版本	11.6
主要开发工具包	PyQt5、Opencv

(2) 参数配置

表 5-2 训练超参数

参数名称	设定值
优化器	Adam
初始学习率	5×10^{-6}
批量大小 (Batch)	16
训练周期 (Epoch)	30 (采用早停机制)
损失函数	交叉熵损失函数

5.1.4 评价指标

本文选择了准确率、精确率、召回率和 F1 得分等评价指标来评估改进后的 ResNet50 模型在视网膜 OCT 图像分类任务中的性能,评价指标地详细介绍见表

5-3。

表 5-3 评估指标表

指标名称	计算公式	临床意义
准确率 (Accuracy)	$\frac{TP + TN}{TP + TN + FP + FN}$	总样本数量中正确分类的目标样本所占比
精确率 (Precision)	$\frac{TP}{TP + FP}$	预测为正类的样本中实际为正类的比例
召回率 (Recall)	$\frac{TP}{TP + FN}$	实际正类中被正确识别的比例（灵敏度）
F1-score	$\frac{2 \times P \times R}{P + R}$	精确率与召回率的调和平均，平衡二者

在这些评价指标中，真阳性（True Positive, TP）、真阴性（True Negative, TN）、假阳性（False Positive, FP）和假阴性（False Negative, FN）是计算每个类别指标的基础，这些指标可以根据每个类别与其他类别之间的关系进行计算。例如针对 AMD 类别，TP 指模型正确预测为 AMD 的样本数，TN 指模型预测为非 AMD 且实际标签也不是 AMD 的样本数，FP 指模型错误预测为 AMD 的非 AMD 样本数，FN 表示模型预测为非 AMD 但实际标签是 AMD 的样本数^[47]。

5.2 对比实验

5.2.1 优化的 ResNet50 模型性能分析

为了验证本章所构建的网络模型在分类任务中的表现，我们基于 PyTorch 框架实现了迁移学习后的 ResNet50 模型，并将 CBAM 模块集成其中进行改进。随后，利用视网膜 OCT 图像数据集对模型进行了训练，并保存了最终得到的训练模型。通过分析模型在视网膜 OCT 数据集上的分类结果，我们绘制了训练过程中在训练集与验证集上的准确率及损失函数值的变化曲线，如图 5-3 所示。

经实验验证，优化后的 ResNet50 模型在测试集上的准确率可达到 97.36%。从图 5-3 中可以看出，验证集的准确率在大部分训练周期内要高于训练集的准确率，而验证集的损失值则普遍低于训练集的损失值。这一现象的原因是，训练过

程中使用了数据增强，使得训练集样本更加多样化且复杂，从而增加了模型学习的难度。相比之下，验证集的数据没有经过太多的随机变换，因此相对简单，模型更容易理解和分类这些图像，从而在验证集上取得了更好的表现。




图 5-3 基于迁移学习的 CBAM-ResNet50 分类准确率与损失值曲线

5.2.2 不同分类模型对比

本文通过对比试验评估四种模型在视网膜 OCT 图像分类任务中的性能，选取优化后的 ResNet50_CBAM、标准 ResNet50、GoogLeNet 和 VGG16 这四种模型，图 5-4 呈现各模型训练时的准确率和损失变化曲线反映收敛速度和稳定性，图 5-5 绘制混淆矩阵分析模型在各类别上的分类效果，表 5-4 汇总测试集上的最终分类准确率来直观比较不同模型的整体性能。




图 5-4 各模型在训练过程中的准确率和损失变化曲线




图 5-5 各模型混淆矩阵

从图 5-4 可以看出 ResNet50_CBAM 在训练过程中存在优势，验证准确率曲线更平滑且早期就达到较高水平、收敛更快，同时验证损失也始终低于其他模型，

体现出较强的泛化能力和稳定性。

整体来看 ResNet50_CBAM 模型在多类别分类任务中的表现优于其他模型，但图 5-5 显示 DME 与 CNV 之间易错误分类，可能是因为 DME 与 CNV 在早期阶段常表现为渗出或视网膜层轻微隆起且边界模糊，导致两者在图像特征上高度相似，增加了模型的区分难度；DRUSEN 与 NORMAL 之间也存在混淆情况，可能是由于部分 DRUSEN 图像中的病灶较小、视觉表现接近正常视网膜，易被误判为 NORMAL。

从各个模型的性能表 5-4 来看，CBAM-ResNet50 的准确率达到 97.36%，是所有模型中表现最好的，比标准 ResNet50、GoogLeNet 和 VGG16 的准确率分别低 1.47%、1.54%和 0.04%。

上面这些结果表明，在相同的实验条件下优化后的 CBAM-ResNet50 模型提升了分类性能，证明了它在视网膜 OCT 图像分类任务中的优势。

表 5-4 各模型性能表

模型名称	准确率	精确率	召回率	F1 值
VGG	97.32	97.34	97.32	97.32
GoogLeNet	95.82	95.87	95.82	95.82
ResNet50	95.89	95.95	95.89	95.89
ResNet50_CBAM	97.36	97.29	97.36	97.36

5.3 消融实验

为了验证卷积块注意力模块（CBAM）对模型性能的提升效果，本文设计了针对性的消融实验，实验包括标准 ResNet50、引入 SE 模块的 ResNet50（ResNet50+SE）、仅在 ResNet50 的最后一层残差块（layer4）后加入 CBAM 的模型（ResNet50+CBAM）以及所有残差块中均嵌入 CBAM 模块的模型（ResNet50+Full-CBAM）四个配置，图 5-6 展示了这四种配置的训练与验证曲线，表 5-5 则汇总了各模型的分类指标，便于我们分析不同注意力模块及其位置对性能的贡献。




图 5-6 ResNet50、SE-ResNet、ResNet50_CBAM 和 ResNet50+Full-CBAM 的训练与验证曲线

本研究首先使用 ResNet50 模型在 Retinal OCT-C8 数据集上进行训练，由于该数据集中的图像存在一定的类间相似性且部分病灶区域较小、特征不明显，增加了分类的难度，图 5-6 显示 ResNet50 模型的训练准确率虽然稳步提升但训练损失下降较慢，验证准确率在前期波动较大，最终稳定在 95.89%，表明该模型在特征提取和泛化能力方面有提升空间；然后在 ResNet50 的基础上引入了通道注意力机制构建的 SE_ResNet50 模型，实验结果显示该模型在训练和验证阶段的准确率都有所提升，验证损失更低且曲线更平稳，说明其在提取细节特征和识别不同病变方面更有效；接着我们引入 CBAM 模块，在模型中同时加入通道和空间注意力构建的 ResNet50_CBAM 模型表现最为优秀，不仅训练和验证准确率最高，收敛速度也更快且损失变化平稳，说明其能更全面地关注图像的关键区域，尤其适合识别细小或模糊的视网膜病灶；最后我们还尝试将 CBAM 模块应用到更多网络层中构建的 ResNet50+Full_CBAM 模型，该模型初期收敛速度较快，整体性能接近 ResNet50_CBAM，但是这个模型的结构更复杂、计算量大，且数据集样本有限，导致在样本数量有限时表现不够稳定。

实验数据显示 ResNet50_CBAM 模型的准确率、收敛速度和稳定性均显著优于对比模型，该模型利用轻量化注意力机制聚焦高层全局特征，既能有效捕捉病变关键区域信息又能控制模块参数量在低水平范围内，避免过拟合风险与计算资源浪费，所以 ResNet50_CBAM 模型凭借小样本场景下出色的泛化能力和工程实用性，成为本系统视网膜图像分类任务的最优主干模型选择。

表 5-5 各模型在数据集上 Retinal OCT-C8 的分类性能

模型名称	类别	精确率	召回率	F1 得分	整体准确率
ResNet50	AMD	1.00	1.00	1.00	0.96
	CNV	0.95	0.90	0.92	
	CSR	1.00	1.00	1.00	
	DME	0.94	0.91	0.92	
	DR	1.00	1.00	1.00	
	Drusen	0.91	0.91	0.91	
	MH	1.00	1.00	1.00	
	Normal	0.88	0.96	0.92	
ResNet50_SE	AMD	1.00	0.99	1.00	0.97
	CNV	0.94	0.95	0.95	
	CSR	0.99	1.00	1.00	
	DME	0.96	0.91	0.92	
	DR	1.00	1.00	1.00	
	Drusen	0.94	0.92	0.95	
	MH	1.00	1.00	1.00	
	Normal	0.96	0.95	0.96	
ResNet50_CBAM	AMD	1.00	1.00	1.00	0.97
	CNV	0.91	0.96	0.94	
	CSR	1.00	1.00	1.00	
	DME	0.97	0.92	0.94	
	DR	1.00	1.00	1.00	
	Drusen	0.96	0.92	0.94	
	MH	1.00	1.00	1.00	
	Normal	0.94	0.97	0.95	
ResNet50_full_CBAM	AMD	1.00	1.00	1.00	0.97
	CNV	0.91	0.95	0.93	
	CSR	1.00	1.00	1.00	
	DME	0.97	0.93	0.95	
	DR	1.00	1.00	1.00	
	Drusen	0.94	0.91	0.92	
	MH	1.00	1.00	1.00	
	Normal	0.93	0.96	0.95	

5.4 本章小结

本章节对 ResNet50_CBAM 模型在视网膜 OCT 图像数据集上的性能进行研究验证。先介绍公开数据集 Retinal OCT-C8、模型性能评价指标及实验环境参数设置,随后通过与其他卷积神经网络模型的对比实验和引入不同注意力机制不同位置的消融实验,验证了探究 ResNet50_CBAM 的优越性以及 CBAM 的位置对模型性能的提升效果,实验结果显示 ResNet50_CBAM 模型在准确率、精确率、召回率以及 F1 得分等指标上表现出优势。

第 6 章 总结与展望

6.1 总结

视网膜疾病患病率的持续上升使得医疗机构积累的 OCT 影像数据呈现指数级增长趋势，传统人工分类方式在处理海量医学影像时容易误诊且效率低下，开发视网膜疾病分类系统能够提升诊断的准确率与效率。

本研究提出基于 ResNet 架构改进的深度学习方法，可以专门用于视网膜 OCT 图像的智能化分类，主要工作包括阐述视网膜数据采集与预处理流程、介绍注意力机制的引进方法、探讨基于迁移学习的模型训练策略及完成视网膜疾病分类系统的设计与实现。

本实验使用了数据来源于 Kaggle 的 Retinal OCT-C8 公开数据集，针对图像的大小差异且需用于模型的训练和评估的情况，在数据预处理时我们采用了多种数据增强技术来在增加数据的多样性以减少过拟合的风险，验证集通过统一尺寸缩放和中心裁剪以确保图像尺寸一致，便于模型评估；选择 PyTorch 作为深度学习框架进行模型训练，我们选用 ResNet50 模型作为基础架构，并在此基础上应用了 CBAM（通道和空间注意力机制）增强模型的特征提取能力来提升性能，同时使用预训练的 ResNet50 权重并针对数据集进行了训练^[48]，实验结果表明 ResNet50_CBAM 模型在训练集和验证集上均表现出色；利用 PyQt5 框架开发视网膜疾病分类系统，实现了视网膜 OCT 图像的上传和识别结果等功能，使得分类更加友好和便捷。

6.2 展望

尽管本研究提出的基于 ResNet50_CBAM 的视网膜疾病分类方法在实验中取得了良好的效果，但仍存在一些不足之处，未来的工作可以在以下几个方面进行改进与拓展：本实验使用的 Retinal OCT-C8 数据集具有一定的代表性但样本量较小，未来可以通过采集来自不同医疗机构的视网膜 OCT 图像，进一步增强数据集的多样性以提升模型的泛化能力；针对视网膜 OCT 图像数量较少且标注困难的问题，未来可以探索更高效的半监督学习网络架构并参考相关领域的最新成果，不断优化模型以提升效率、降低计算成本；在系统现有准确识别视网膜疾病

类别功能的基础上，未来可加入在线答疑、专家建议等模块^[49]功能，进一步增强用户体验并提升实际应用中的价值。

致 谢

行文至此，感想颇多。这篇文章不仅代表着我这几年学习成果，也意味着我学生生涯的终点。在此，我想向所有在本研究过程中给予帮助和支持的人表示衷心的感谢。

首先，我要衷心感谢我的导师——高恩婷教授，她对我整个毕设的完成进行了全面而细致的指导，从论文的选题、开题报告一直到论文的完成都倾注了老师的大量心血。虽然平时工作比较忙，但经常抽出时间面对面对我进行细心的指导。帮助我解决了我在课题研究中产生的问题、遭遇的困难，使我在日常工作学习中少走了很多弯路。我还要特别感谢同组同学和师兄，他们在各方面给予了我极大的帮助，让我的这项工作得以顺利进行，也让我收获了很多宝贵的经验。

最后，我要感谢我的家人及朋友对我在研究过程中无私的支持与理解。

参 考 文 献

- [1] 肖一同.基于深度学习的视网膜病变 OCT 图像分类算法研究[D].南昌大学,2024.DOI:10.27232/d.cnki.gnchu.2024.002476.
- [2] 李静雯,王令珑,赵阳光,等.机器学习在眼科疾病辅助诊疗中的应用及监管[J].信息通信技术与政策,2023,49(09):87-91.
- [3] 王迪.基于视网膜的光学相干层析血管造影术的研究[D].桂林电子科技大学,2024.DOI:10.27049/d.cnki.gglde.2024.000052.
- [4] Yu W ,Yaonan Z ,Zhaomin Y , et al.Machine learning based detection of age-related macular degeneration (AMD) and diabetic macular edema (DME) from optical coherence tomography (OCT) images.[J].Biomedical optics express,2016,7(12):4928-4940.
- [5] 朱盛滔.基于深度学习的乳腺超声图像病灶分割算法研究[D].西京学院,2024.DOI:10.27831/d.cnki.gxjxy.2024.000044.
- [6] Albarrak A ,Coenen F ,Zheng Y .Volumetric image classification using homogeneous decomposition and dictionary learning: A study using retinal optical coherence tomography for detecting age-related macular degeneration[J].Computerized Medical Imaging and Graphics,2017,55:113-123.
- [7] P P S ,A L K ,S P M , et al.Fully automated detection of diabetic macular edema and dry age-related macular degeneration from optical coherence tomography images.[J].Biomedical optics express,2014,5(10):3568-77.
- [8] Khaled A ,Guillaume L ,Mojdeh R , et al.Machine learning techniques for diabetic macular edema (DME) classification on SD-OCT images.[J].Biomedical engineering online,2017,16(1):68.
- [9] Yankui S ,Shan L ,Zhongyang S .Fully automated macular pathology detection in retinal optical coherence tomography images using sparse coding and dictionary learning.[J].Journal of biomedical optics,2017,22(1):16012.
- [10] Liu Y ,Chen M ,Ishikawa H , et al.Automated macular pathology diagnosis in retinal OCT images using multi-scale spatial pyramid and local binary patterns in texture and shape encoding[J].Medical Image Analysis,2011,15(5):748-759.
- [11] Leyuan F ,Chong W ,Shutao L , et al.Automatic classification of retinal three-dimensional optical coherence tomography images using principal component analysis network with composite kernels.[J].Journal of biomedical optics,2017,22(11):1-10.
- [12] G. F V ,Bram G V ,Bart B , et al.Automated age-related macular degeneration classification in OCT using unsupervised feature learning[J].Radboud Univ. Nijmegen Medical Ctr. (Netherlands);Univ. of Michigan Health System (United States);Oak Ridge National Lab. (United States),2015,941494141I-94141I-7.
- [13] 宋丹.眼底视网膜 OCT 图像识别研究与应用[D].桂林理工大学,2020.DOI:10.27050/d.cnki.gglgc.2020.000243.

- [14] Y. C L ,L.D. J .Handwritten digit recognition: applications of neural network chips and automatic learning[J].IEEE Communications Magazine: Articles, News, and Events of Interest to Communications Engineers,1989,27(11):41-46.
- [15] Krizhevsky A ,Sutskever I ,Hinton E G .ImageNet classification with deep convolutional neural networks[J].Communications of the ACM,2017,60(6):84-90.
- [16] Simonyan K ,Zisserman A .Very Deep Convolutional Networks for Large-Scale Image Recognition.[J].CoRR,2014,abs/1409.1556
- [17] He K ,Zhang X ,Ren S , et al.Deep Residual Learning for Image Recognition.[J].CoRR,2015,abs/1512.03385
- [18] Muhammad N ,Samabia T ,Sairam A , et al.Retinal images benchmark for the detection of diabetic retinopathy and clinically significant macular edema (CSME).[J].Biomedizinische Technik. Biomedical engineering,2019,64(3):297-307.
- [19] 王翀,何兴鑫,方乐缘等.Automatic Classification of Retinal Optical Coherence Tomography Images via Convolutional Neural Networks with Joint Decision[J].中国生物医学工程学报, 2018, 37(6):641-648.
- [20] Kermany S D ,Goldbaum M ,Cai W , et al.Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning[J].Cell,2018,172(5):1122-1131.e9.
- [21] 史佳翔.基于 SOC FPGA 的卷积神经网络加速系统设计与实现[D].哈尔滨理工大学,2021. DOI:10.27063/d.cnki.ghlgu.2021.000641.
- [22] H D H ,N T W .Receptive fields of single neurones in the cat's striate cortex.[J].The Journal of physiology,1959,148:574-91.
- [23] K F .Neocognitron: a self organizing neural network model for a mechanism of pattern recognition unaffected by shift in position.[J].Biological cybernetics,1980,36(4):193-202.
- [24] 李广庆.基于深度学习的视网膜 OCT 图像分类方法研究[D].哈尔滨理工大学,2023.DOI:10.27063/d.cnki.ghlgu.2023.001173.
- [25] 张晋禄.基于深度学习的人脸图像超分辨率特征重建的研究[D].黑龙江大学,2023.DOI:10.27123/d.cnki.ghlju.2023.000601.[1]
- [26] 余婷.基于卷积神经网络的三维地震断层识别[D].中国矿业大学,2023.DOI:10.27623/d.cnki.gzkyu.2023.002417.
- [27] 刘存哲.基于参考的图像去模糊算法研究[D].山东工商学院,2023.DOI:10.27903/d.cnki.gsdsq.2023.000068.
- [28] 叶金金.基于卷积神经网络的水下图像增强算法研究[D].海南大学,2023.DOI:10.27073/d.cnki.ghadu.2023.000127.
- [29] 肖家乐.基于深度学习的甜菜田间杂草分类与分割方法研究[D].浙江科技大学,2025.DOI:10.27840/d.cnki.gzjkj.2025.000040.
- [30] 杜宝玉.基于卷积神经网络的类增量学习图像分类方法研究[D].齐鲁工业大学,2024.DOI:10.27278/d.cnki.gsdqc.2024.000128.

- [31] 王园园.基于深度学习的液晶模组导电粒子检测方法研究[D].郑州大学,2022.DOI:10.27466/d.cnki.gzzdu.2022.001229.
- [32] 胡莹晖.基于卷积神经网络的皮肤镜图像分类研究[D].湖北师范大学,2024.DOI:10.27796/d.cnki.ghbsf.2024.000121.
- [33] 商敬量.基于深度学习的游梁式抽油机故障诊断研究[D].东北石油大学,2023.DOI:10.26995/d.cnki.gdqsc.2023.000399.
- [34] 唐娥.基于贝叶斯优化和迁移学习的锂电池剩余使用寿命预测[D].江西理工大学,2024.DOI:10.27176/d.cnki.gnfyc.2024.001118.
- [35] 刘威.基于小样本学习的表面缺陷检测与分类技术研究[D].华东交通大学,2023.DOI:10.27147/d.cnki.ghdju.2023.000877.
- [36] 赵园园.基于深度学习的小样本图像分类方法研究[D].重庆邮电大学,2021.DOI:10.27675/d.cnki.gcydx.2021.000586.
- [37] 夏禹康.基于深度迁移学习的印刷机轴承故障诊断研究[D].西安理工大学,2024.DOI:10.27398/d.cnki.gxalu.2024.000402.
- [38] 张延顺,宁远涛,黄涛,等.基于 STM32 和 PyQt5 的分子泵监控系统设计与实现[J].工业仪表与自动化装置,2025,(02):60-63+104.DOI:10.19950/j.cnki.CN61-1121/TH.2025.02.011.
- [39] 李子恒.基于改进 YOLOv5 的口罩及安全帽检测系统研究与实现[D].安徽工业大学,2021.DOI:10.27790/d.cnki.gahgy.2021.000634.
- [40] 张昆,袁博涵,崔静莹,等.基于计算机视觉的茶叶嫩芽识别方法研究进展[J].山东农业科学,2024,56(05):163-170.DOI:10.14083/j.issn.1001-4942.2024.05.021.
- [41] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [42] 张建飞.基于 VMD-CWT 与 CBAM-ResNet 的柱塞泵故障诊断研究[D].中北大学,2023.DOI:10.27470/d.cnki.ghbgc.2023.001135.
- [43] 赵莉.基于深度学习的无人机空对空目标检测与跟踪算法研究[D].西安理工大学,2024.DOI:10.27398/d.cnki.gxalu.2024.000608.
- [44] 黄辉,肖豪,王琼瑶,等.基于改进 YOLOv5 与 CRNN 的电表示数识别[J].电子测量技术,2023,46(01):173-180.DOI:10.19651/j.cnki.emt.2210303.
- [45] 李智.基于深度学习的视频监控多目标检测和追踪算法研究与应用[D].长江大学,2023.DOI:10.26981/d.cnki.gjhsc.2023.000346.
- [46] 郑亚丽.基于无人机的路面破损状况检测方法研究[D].内蒙古工业大学,2023.DOI:10.27225/d.cnki.gnmgu.2023.000088.
- [47] 王一凡,石超君,马晓洁,等.2 型糖尿病并发动脉粥样硬化风险预测模型比较[J].医学信息学杂志,2024,45(07):74-80.
- [48] 刘诗瑶.基于深度学习的视频连续手语识别方法研究[D].哈尔滨工程大学,2023.DOI:10.27060/d.cnki.ghbcu.2023.001597.
- [49] 车美娜.基于深度学习—注意力机制的水稻病虫害识别研究[D].吉林农业大学,2024.DOI:10.27163/d.cnki.gjlau.2024.000579.